

Modelagem da Vitória do Time Mandante no Campeonato Brasileiro Série A de 2024 por meio de um Modelo Linear Generalizado

Autor: Richard Salustriano da Silva

Resumo

Este trabalho tem como objetivo desenvolver um Modelo Linear Generalizado (MLG) com distribuição Bernoulli e função de ligação logito (ou seja, uma regressão logística) para investigar como variáveis ofensivas, contextuais e de valor do elenco se associam à vitória do time mandante no Campeonato Brasileiro Série A de 2024. A variável resposta foi definida como 1 quando o time da casa venceu o jogo e 0 nos casos de empate ou derrota. A análise foi realizada com base em uma amostra de 204 partidas, considerando preditores como Gols esperados (xG) do mandante, número de chutes, valor de mercado do elenco titular, posição relativa na tabela e porcentagem de ocupação do estádio (calculada como razão entre público presente e capacidade máxima do local). No fim apenas as variáveis gols esperados e presença da torcida se mostraram boas preditoras para o modelo.

Palavras-chave: futebol; modelos lineares generalizados; regressão logística; gols esperados; desempenho esportivo.

Introdução

O futebol é, há décadas, o esporte mais popular no Brasil, tanto do ponto de vista cultural quanto comercial. Com o avanço da ciência de dados e da estatística aplicada ao esporte, tornou-se possível ir além das análises tradicionais — baseadas em médias de gols ou posse de bola — e adotar abordagens mais rigorosas, capazes de quantificar a influência de fatores contextuais, táticos e econômicos sobre o desempenho das equipes.

A maioria dos artigos que tratam de previsão de jogos de futebol usam distribuição Poisson para fazer isso. Por isso decidi fazer algo diferente: analisar 204 partidas do brasileiro 2024 usando um modelo linear generalizado bernoulli com função de ligação logito. A metodologia incluiu a criação de uma variável de porcentagem de presença no estádio, faixas de intervalo para criação das estatísticas descritivas e a junção de bases externas. Desta forma, espero contribuir um pouco com a evolução da discussão nessa área da estatística aplicada ao futebol do Brasil. Outra motivação é o meu interesse em aplicar técnicas estatísticas em contextos esportivos.

O que é o time mandante?

O time mandante é o time que joga em casa, geralmente no seu estágio perto da sua torcida, a literatura mostra que esse time tem vantagem sobre o time visitante. De fato, o time mandante teve 99 vitórias e 48 derrotas.

Fonte

A fonte vem do site basedosdados.org. Este site reúne diversas bases de dados sobre diversos assuntos como educação, saúde, esporte etc.

Além disso, foram utilizados dados do site [Sofascore.com](https://www.sofascore.com)

<https://www.sofascore.com/pt/torneio/futebol/brazil/brasileirao-serie-a/325#id:58766>

para integrar as estatísticas de gols esperados e cartões vermelhos.

Tratamento dos dados

Primeiro juntei a base do Sofarscore com a do site Basedosdados.org. Depois apenas tive o trabalho de filtrar para o ano de 2024 e criar variáveis auxiliares para as análises descritivas que serão vistas a frente. Como, por exemplo, a criação da variável `proc_publico`. Esta variável indica a porcentagem de público presente no dia da partida, ela foi criada dividindo o público presente pela capacidade total do estádio. Depois criei as faixas de intervalo para algumas variáveis com o objetivo de fazer as estatísticas descritivas. Por fim, retirei os poucos resultados vazios que restaram

Revisão bibliográfica

KHRAPACH, Valerii; SIRYI, Oleksandr. *Statistical Metric Expected Goals in Football and Its Impact on Scoring Performance: a review article*. Health Technologies, 2024.

Segundo Khrapach e Siryi (2024), o xG incorpora características essenciais da jogada — como distância, ângulo, tipo do chute e pressão defensiva — oferecendo uma estimativa mais informativa da capacidade ofensiva do que estatísticas tradicionais de gols marcados. Os autores destacam ainda que o xG é altamente associado ao desempenho real das equipes ao longo de competições, sendo considerado um dos melhores preditores contemporâneos de resultado

Explicando as variáveis

1. `xG_mandante` (**Gols esperados – Mandante**)

- Tipo: Contínua
- Descrição: Cada finalização está associada a um número entre zero e 1 feita pelo time da casa, com base em fatores como localização, distância do chute e situação do jogo etc. Alguns sites que produzem essa estatística levam em conta também a posição dos defensores outros não
- Interpretação: Quanto maior o xG, maior a qualidade das chances criadas pelo mandante, independentemente de os gols terem sido concretizados. É uma métrica mais refinada que o número de gols ou chutes.

2. `porc_publico` (**Porcentagem de ocupação do estádio**)

- Tipo: Contínua (fica entre 0%–100%)
- Descrição: Razão entre o número de torcedores presentes no estádio e a capacidade total dele
- Interpretação: Mede o apoio da torcida local. Um público mais numeroso pode influenciar psicologicamente os jogadores e até a arbitragem, potencialmente aumentando a chance de vitória do mandante.

3. `colocacao_mandante` (**Posição absoluta na tabela do campeonato**)

- Tipo: Ordinal (inteiro entre 1 e 20)
- Descrição: Indica em que posição o time da casa se encontrava na classificação geral do Campeonato Brasileiro Série A antes da rodada do jogo analisado.

- Interpretação: Times melhor colocados geralmente têm elencos mais fortes e desempenho mais consistente, o que pode estar associado a maior probabilidade de vitória.
-

4. posição_relativa

- Tipo: Contínua
 - Descrição: Diferença entre a colocação do time da casa e a do visitante (ex: colocacao_visitante - colocacao_mandante).
 - Interpretação: Captura o desequilíbrio competitivo entre os times. Valores positivos indicam que o mandante está melhor colocado que o visitante, sugerindo maior chance de vitória.
-

5. valor_equipe_titular_mandante

- Tipo: Contínua
 - Descrição: Soma do valor de mercado (em milhares de euros, conforme a fonte) dos jogadores titulares do time da casa.
 - Interpretação: Reflete o investimento e o “talento individual” do elenco. Times com maior valor tendem a ter melhor desempenho, embora isso nem sempre se traduza em resultados.
-

6. cartão_vermelho_mandante

- Tipo: categórica
 - Descrição: 1 se o time mandante tomou pelo menos 1 cartão vermelho durante a partida, zero caso contrário
 - Interpretação: Jogar com um jogador a menos é sempre complicado, espera-se que isso influencia negativamente no resultado do time mandante
-

7. chutes_mandante

- Tipo: Contagem (inteiro ≥ 0)
 - Descrição: Número total de arremates a gol feitos pelo time da casa, incluindo chutes bloqueados, para fora e no alvo.
 - Interpretação: Embora menos sofisticado que o xG, ainda é um indicador de domínio ofensivo.
-

metodologia

O método utilizado neste trabalho é facilmente replicável.

Após integrar as bases de dados contendo as informações das partidas, utilizei os softwares R e Excel para realizar as análises descritivas. Para isso, criei faixas de intervalos nas variáveis contínuas, com o objetivo de facilitar a interpretação dos resultados descritivos. Por exemplo, os chutes do time mandante foram agrupados nas seguintes categorias: “menos de 10”, “entre 11 e 15” e “mais que 15”.

Criei a variável saldo diminuindo os gols do time visitante com os gols do time mandante para criar a variável vitória (variável resposta)

Inicialmente usei o método stepwise para reduzir a quantidade de variáveis
Depois retirei as variáveis não significativas para chegar no modelo final

Análise exploratória


Chute por vitória do time mandante

Chute	não vitória	Vitória	Total	Porcentagem
Menos que 10	19	13	32	40,63%
Entre 11 e 15	46	48	94	51,06%
Mais que 15	40	38	78	48,72%

Não parece haver uma relação clara entre chute e vitória

Posição no campeonato do time mandante por vitória

Faixa	Jogos	Vitórias	Proporção de vitórias
1–5	78	41	52.6%
6–10	61	24	39.3%
11–15	48	22	45.8%
16–20	12	12	100%



Apesar de haver uma leve intersecção entre os boxplots, os times com posição relativa alto parece vencer mais jogos

Relação dos times que tomaram pelos menos 1 cartão vermelho e vitória


Cartão vermelho	Não Vitória	Vitória	Total Geral	porcentagem
Não	86	90	176	51,14%
Sim	19	9	28	32,14%

Porcentagem da torcida no estádio por vitória

Torcida	Vitória do mandante
>=30.000	53,85%
20.000-29.999	44,19%
15.000-19.999	45,00%
10.000-14.999	37,50%
5.000-9.999	46,15%
0-4.999	61,54%

Distribuição de Gols Esperados (xG) por Resultado do Mandante

Comparação da Qualidade das Chances Criadas



Grupo	Média de gols esperados(xg)	Mediana	Número de jogos
Vitórias	1.56	1	99
Não vitórias	1.12	1.43	105


Faixa de Gols Esperados	Não vitória	vitória	Total Geral	Porcentagem
Maior que 1,5	30	48	78	61,54%
Entre 1 e 1,5	22	28	50	56,00%
Entre 0,5 e 1	29	20	49	68,97%
Menor que 0,5	24	3	27	11,11%
Total Geral	105	99	204	

Análise dos resultados

Modelo inicial

variável	estimativa	erro padrão	z-valor	p-valor
intercepto	1,43E+00	9,66E-01	1,484	0,1379
xg_mandante	1,43E+00	3,31E-01	4,329	1,50E-05
colocacao_mandante	2,20E-04	5,02E-02	0,004	0,9965
porc_publico	-1,17E+00	7,53E-01	-1,549	0,12143
posição_relativa	1,57E-01	3,43E-02	4,574	4,78E-06
Valor_equipe_titular	-1,17E-04	9,19E-05	-1,269	0,2045
chutes_mandante	-1,49E-01	4,70E-02	-3,172	0,00151
cartão_vermelho_mandante	-9,11E-01	5,24E-01	-1,74	0,0818

Análise de Correlação do modelo inicial



A matriz de correlação mostra que as variáveis mais correlacionadas são os gols esperados e o chute, a correlação foi de aproximadamente 0,52. Por isso decidi retirar a variável chute do modelo final

E também as variáveis colocação do mandante e posição relativa tem uma correlação negativa de aproximadamente 0,72

O VIF é uma medida preditora que mostra o quanto a variância do coeficiente de regressão estimado está inflacionada (aumentada) devido à correlação linear com as *outras* variáveis preditoras do modelo.

$$vif = \frac{1}{1 - R_j^2}$$

VIF no modelo inicial


Variavel	VIF
xg_mandante	1,56
porc_publico	1,14
colocacao_mandante	2,52
posicao_relativa	2,19
valor_equipe_titular_mandante	1,47
chutes_mandante	1,61
Cartão_vermelho_mandante	1,04

Todos os fatores de influência da variância são baixos portanto **não há problemas de multicolinearidade** graves no modelo inicial

Modelo usando o método stepwise

variável	estimativa	erro padrão	z-valor	p-valor
Intercepto	1,44E+00	7,05E-01	2,035	0,04182
xg_mandante	1,43E+00	3,30E-01	4,335	1,46E-05
porc_publico	-1,17E+00	7,49E-01	-1,556	0,11973
posição_relativa	1,57E-01	2,59E-02	6,037	1,57E-09
valor_equipe_titular	-1,17E-04	8,52E-05	-1,37	0,17065
chutes_mandante	-1,49E-01	4,69E-02	-3,179	0,00148
cartão_vermelho_mandante	-9,11E-01	5,24E-01	-1,741	0,08177

Análise de Correlação do modelo stepwise



Novamente a maior correlação é entre a variável chute e gols esperados

Por isso decidi retirar a variável chute

Decidi retirar também a variável porc_publico, cartão vermelho e valor do time mandante por se mostrarem menos significativas

Modelo final

variável	estimativa	erro padrão	z-valor	p-valor
Intercepto	-1,08693	0,35364	-3,074	0,00212
xg_mandante	0,76292	0,24324	3,136	0,00171
posição_relativa	0,13334	0,02236	5,963	2,48E-09

O modelo final na forma teórica , fica:

$$\ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Calculando a deviance temos

$$P(D_{200} > D_{obs}) = P(D_{200} > 216,7) = 0,3220215$$

Não rejeitamos a hipótese nula que o modelo é tão bom quanto o maximal

Conclusão

Avaliando os modelos usando BIC

Modelo inicial	239,67
Modelo stepwise	234,35
Modelo final	232,63

Avaliando os modelos usando AIC

Modelo inicial	213,16
Modelo stepwise	211,16
Modelo final	222,69

Após um processo de seleção de variáveis baseado no método *stepwise* e na análise de significância estatística, o modelo final revelou que 2 variáveis apresentaram relação significativa com a probabilidade de vitória:

- xG do mandante mostrou-se positivamente associado à vitória, reforçando a literatura contemporânea que aponta o xG como uma métrica robusta para avaliar a qualidade ofensiva.
- Interpretação da Razão de Chances: Para cada aumento de 1 unidade no `xg_mandante` (mantendo todas as outras variáveis constantes), a chance (odds) de vitória do time mandante aumenta em aproximadamente 114,47%.
- Posição relativa entre os times (diferença entre a colocação do mandante e do visitante) também teve um efeito positivo e altamente significativo, indicando que a vantagem competitiva é um fator determinante para o resultado.
- Interpretação da Razão de Chances: Para cada 1 ponto de melhoria na `posição_relativa` (ou seja, para cada posição que o time mandante está melhor em relação ao visitante), a chance (odds) de vitória do time mandante aumenta em aproximadamente 14,3%

As outras variáveis não parecem serem boas preditivas para a vitória do time mandante como as análises exploratórias já pareciam indicar

Referências

KHRAPACH, Valerii; SIRYI, Oleksandr. *Statistical Metric Expected Goals in Football and Its Impact on Scoring Performance: a review article*. Health Technologies, v. 2, n. 3, p. 47-54, 2024. DOI:

GODDARD, John; ASIMAKOPOULOS, Ioannis. Forecasting football match results and the efficiency of fixed-odds betting. *Journal of Forecasting*, v. 23, n. 1, p. 51–66, 2004

MAHER, Michael J. Modelling association football scores. *Statistica Neerlandica*, v. 36, n. 3, p. 109–118, 1982